

EMMA — Guida completa

Assistente personale self-hosted · versione 1, solo testo

31 agosto 2026

Introduzione

Questa guida porta un server Ubuntu appena installato ad avere EMMA in funzione: un assistente personale con cui chatti da Telegram, che gira su hardware tuo e che parla con un modello linguistico attraverso l'API di Anthropic o quella di Groq, a scelta.

È il manuale completo di riferimento. Il `README.md` del repository è la guida rapida in inglese per chi vuole solo provarlo; questa guida è quella da seguire per installarlo davvero, capirlo e mantenerlo nel tempo. Seguendola dall'inizio alla fine non ti serve cercare informazioni altrove.

Cosa fa EMMA nella versione 1. Scrivi al tuo bot Telegram dal telefono. Un servizio Python sul tuo server riceve il messaggio, ci aggiunge la conversazione recente, chiede una risposta al modello e te la rimanda. Il bot risponde solo a te. Il modello si sceglie in configurazione: Claude tramite l'API di Anthropic, oppure Groq, che ha un piano gratuito. La conversazione è salvata su disco e sopravvive ai riavvii. Non c'è voce e non ci sono strumenti: è la fondazione, e tutto il resto arriverà sopra questa.

A chi si rivolge. A chi sa muoversi in un terminale Linux ma non dà nulla per scontato. Ogni comando è scritto per intero e ogni scelta è motivata, perché fra sei mesi vorrai sapere non solo *cosa* hai fatto ma *perché*.

Convenzioni.

- I comandi preceduti da `sudo` vanno eseguiti da un utente con privilegi amministrativi; gli altri dal tuo utente normale.
- Dove compare `/opt/emma`, è la directory di installazione: se la cambi, cambiala ovunque (nella guida e nei file in `systemd/`, dove le righe da toccare sono marcate con `# PATH:`).
- Dove compare `<tuoi-account>`, sostituisci il tuo nome utente GitHub.
- I blocchi marcati **Verifica** dicono cosa devi vedere per essere sicuro che il passo sia andato a buon fine. Non saltarli: è così che si evita di scoprire un errore tre capitoli dopo.

I sei capitoli.

1. **Preparazione dell'ambiente** — dal server nudo al sistema pronto.
2. **Architettura** — com'è fatto EMMA e perché.
3. **Implementazione** — il codice, file per file.
4. **Deploy** — configurazione, servizio `systemd`, primo avvio.
5. **Utilizzo** — l'uso quotidiano dal telefono e i limiti noti.
6. **Manutenzione** — log, aggiornamenti, backup, ripristino, problemi comuni.

Capitolo 1 — Preparazione dell'ambiente

1.1 Quale Ubuntu, e perché

Scelta: Ubuntu Server 24.04 LTS (Noble Numbat).

Le LTS attualmente supportate sono la 24.04 (aprile 2024, supporto standard fino ad aprile 2029) e la 26.04, uscita nel 2026 e quindi con la finestra di supporto più lunga. Per questo progetto scelgo la 24.04 per tre motivi concreti:

- **è matura.** Ha alle spalle anni di point release: i bug di gioventù su driver, rete e installer sono risolti, e su un vecchio PC riciclato — che è esattamente il tuo caso — la compatibilità hardware già collaudata vale più di qualunque novità.
- **la documentazione di terze parti è enorme.** Quando qualcosa non funziona, cercando un messaggio d'errore trovi risposte scritte per la 24.04. Su una LTS appena uscita si finisce spesso a tradurre istruzioni pensate per la precedente.
- **ha Python 3.12**, che soddisfa con margine il requisito 3.11+ del progetto.

La 26.04 LTS è una scelta altrettanto legittima se preferisci il supporto più lungo: EMMA ci gira senza modifiche (Python 3.13, anch'esso compatibile). Tutti i comandi di questa guida valgono per entrambe. Quello che **non** consiglio è una release intermedia non-LTS: nove mesi di supporto significano un aggiornamento maggiore quasi ogni anno su una macchina che deve solo stare accesa e funzionare.

Scarica solo la variante Server, non la Desktop: niente ambiente grafico significa meno RAM occupata, meno pacchetti da aggiornare e meno superficie d'attacco. L'immagine è su <https://ubuntu.com/download/server>.

Durante l'installazione:

- crea il tuo utente personale (quello con cui farai ssh), non serve altro;
- **installa OpenSSH server** quando l'installer lo propone: è l'unico modo per amministrare la macchina senza monitor e tastiera attaccati;
- non installare snap aggiuntivi (Docker, Kubernetes e simili): non servono.

1.2 Verifica del punto di partenza

Collegati via SSH e guarda cosa hai:

```
ssh tuo-utente@indirizzo-del-server
```

```
lsb_release -a          # versione di Ubuntu
python3 --version        # deve essere >= 3.11
free -h                 # memoria disponibile
df -h /                  # spazio sul disco di sistema
ip -brief address        # indirizzi di rete
```

Verifica. `python3 --version` deve rispondere `Python 3.12.x` (o superiore) e `df -h /` deve mostrare almeno 5 GB liberi. EMMA occupa poche decine di MB, ma `virtualenv`, `log` e `backup` vogliono respiro.

1.3 Aggiornamento del sistema

Prima di installare qualunque cosa, allinea il sistema:

```
sudo apt update
sudo apt upgrade -y
sudo reboot          # solo se l'upgrade ha toccato il kernel
```

Se apt segnala che è richiesto un riavvio (`*** System restart required ***`), riavvia adesso: un kernel a metà strada è la causa più stupida di problemi successivi.

1.4 Pacchetti di sistema

Tutti dai repository ufficiali di Ubuntu. **Non aggiungiamo nessun PPA né repository esterno**, e vale la pena dire perché: ogni repository di terze parti è un soggetto che può pubblicare pacchetti sulla tua macchina con i privilegi di root, e va aggiornato e fidato per anni. Qui non serve: tutto ciò di cui EMMA ha bisogno è nei repository ufficiali, e le librerie Python arrivano da PyPI dentro un virtualenv isolato, senza toccare il Python di sistema.

```
sudo apt install -y \
    python3 \
    python3-venv \
    python3-pip \
    git \
    curl \
    ca-certificates \
    tar \
    gzip
```

A cosa serve ciascuno:

Pacchetto	Perché
python3	l'interprete; già presente, lo elenchiamo per completezza
python3-venv	crea l'ambiente virtuale isolato del progetto
python3-pip	installa le dipendenze dentro quell'ambiente
git	scarica il codice e permette di tornare a una versione precedente
curl	verifiche manuali (l'endpoint <code>/health</code> , la connettività)
ca-certificates	certificati radice per le connessioni HTTPS verso Anthropic e Telegram
tar, gzip	usati da <code>scripts/backup.sh</code> (di norma già installati)

Verifica.

```
python3 -m venv --help > /dev/null && echo "venv ok"
git --version
curl -sI https://api.anthropic.com | head -1
```

L'ultimo comando deve restituire una riga HTTP/...: qualunque risposta va bene, significa che il server raggiunge Internet in HTTPS. Se non risponde nulla, il problema è di rete o di DNS e va risolto prima di proseguire.

1.5 Utente di sistema dedicato

EMMA non deve girare come te, e tantomeno come root. Le va creato un utente apposta, **senza possibilità di login e senza privilegi**: se un giorno una skill avrà un bug o una dipendenza si rivelerà malevola, il danno resta confinato a ciò che quell'utente può toccare — cioè quasi nulla.

```
sudo useradd --system --create-home --home-dir /opt/emma --shell /usr/sbin/nologin e
```

Cosa fanno le opzioni:

- `--system`: utente di servizio, con UID basso, escluso dalle liste di login;
- `--create-home --home-dir /opt/emma`: la home coincide con la directory di installazione, così il servizio ha un posto suo dove stare;
- `--shell /usr/sbin/nologin`: nessuno può fare login come emma, nemmeno con la password giusta, perché una password non esiste.

Verifica.

```
id emma
# uid=999(emma) gid=999(emma) groups=999(emma)
sudo -u emma whoami
# emma
```

1.6 Directory di installazione e permessi

```
sudo mkdir -p /opt/emma
sudo chown emma:emma /opt/emma
sudo chmod 750 /opt/emma
```

750 significa: emma legge e scrive, il gruppo emma legge, tutti gli altri utenti della macchina non vedono nemmeno il contenuto. Dato che dentro finirà il file `.env` con la tua chiave API, è il minimo.

Per lavorare comodamente aggiungiti al gruppo emma:

```
sudo usermod -aG emma $USER
newgrp emma          # applica il nuovo gruppo alla sessione corrente
```

Senza questo passaggio dovresti anteporre `sudo -u emma` a ogni comando dentro `/opt/emma`. Nota che `newgrp` vale solo per la shell corrente: alla prossima connessione SSH il gruppo sarà già attivo da solo.

1.7 Il secondo disco per i backup

Tu ragioni in termini di “disco D”, che su Windows è una lettera; su Linux un secondo disco fisico è un dispositivo da montare in un punto dell'albero delle directory. Il risultato è lo stesso — dati su un disco diverso da quello di sistema — ma la procedura è questa.

Se non hai un secondo disco, puoi saltare al capitolo 2 e lasciare `BACKUP_DIR` sul disco di sistema: i backup funzioneranno lo stesso e ti proteggeranno da errori tuoi, ma non dal guasto del disco. È un compromesso da fare consapevolmente, e da correggere appena hai un disco in più.

1.7.1 Identificare il disco

```
lsblk -o NAME,SIZE,TYPE,FSTYPE,MOUNTPOINT,MODEL
```

Esempio di output:

```
NAME      SIZE TYPE FSTYPE MOUNTPOINT MODEL
sda       240G disk                KINGSTON_SA400
├─sda1     1G part vfat    /boot/efi
└─sda2 239G part ext4    /
sdb       500G disk                WDC_WD5000AAKX
```

Qui sda è il disco di sistema (contiene /) e sdb è il secondo disco, ancora senza filesystem e senza punto di mount. **Controlla due volte la lettera prima di proseguire:** i comandi che seguono cancellano il contenuto del disco che indichi.

1.7.2 Partizionare e formattare

Attenzione: i due comandi seguenti distruggono tutti i dati su `/dev/sdb`. Se il disco contiene qualcosa che ti serve, copialo altrove prima.

```
sudo parted /dev/sdb --script mklabel gpt mkpart primary ext4 0% 100%
sudo mkfs.ext4 -L backup /dev/sdb1
```

ext4 è la scelta giusta qui: stabile, supportata ovunque, senza opzioni da capire. L'etichetta backup serve fra un attimo.

1.7.3 Montarlo in modo permanente

Un mount a mano sparisce al riavvio. Perché sia permanente va scritto in `/etc/fstab`, e va scritto usando l'**UUID** del filesystem, non `/dev/sdb1`: i nomi dei dispositivi possono cambiare fra un avvio e l'altro se aggiungi o togli un disco, l'UUID no.

```
sudo mkdir -p /mnt/backup
sudo blkid /dev/sdb1
# /dev/sdb1: LABEL="backup" UUID="1a2b3c4d-..." TYPE="ext4"
```

Copia l'UUID e aggiungi la riga a `/etc/fstab`:

```
sudo cp /etc/fstab /etc/fstab.bak # rete di sicurezza
echo 'UUID=1a2b3c4d-... /mnt/backup ext4 defaults,nofail 0 2' | sudo tee -a /etc/fstab
```

L'opzione **nofail** è importante: senza di essa, se un giorno il disco si guasta o lo stacchi, il server non completa l'avvio e resta bloccato in emergency mode — con l'assistente spento per un problema di backup. Con nofail prosegue e il backup fallisce con un messaggio chiaro nei log, che è il comportamento giusto.

```
sudo systemctl daemon-reload
sudo mount -a
```

Verifica.

```
findmnt /mnt/backup
df -h /mnt/backup
```

Se `mount -a` non dà errori e `findmnt` mostra il disco, la riga di `fstab` è corretta e il montaggio sopravviverà al riavvio. Un errore qui va risolto adesso: un `fstab` sbagliato impedisce l'avvio della macchina.

1.7.4 La directory dei backup

```
sudo mkdir -p /mnt/backup/emma
sudo chown emma:emma /mnt/backup/emma
sudo chmod 700 /mnt/backup/emma
```

700 perché gli archivi contengono il `.env`, quindi la tua chiave API: solo l'utente `emma` deve poterli leggere. Questo percorso è quello che scriverai in `BACKUP_DIR` nel capitolo 4.

1.8 Firewall

EMMA non espone nulla in ingresso: parla con Telegram e con il provider LLM aprendo connessioni in uscita, e l'endpoint `/health` è in ascolto solo su `127.0.0.1`, raggiungibile unicamente dalla macchina stessa. Il firewall quindi non deve aprire niente per EMMA: deve solo lasciarti entrare in SSH.

```
sudo ufw default deny incoming
sudo ufw default allow outgoing
sudo ufw allow OpenSSH
sudo ufw enable
```

Prima di dare `ufw enable`, assicurati che `sudo ufw allow OpenSSH` sia andato a buon fine. Attivare il firewall senza aver aperto SSH ti chiude fuori dalla macchina, e per rientrare serve monitor e tastiera.

Verifica.

```
sudo ufw status verbose
```

Devi vedere `Default: deny (incoming), allow (outgoing)` e una sola regola consentita, `22/tcp (OpenSSH)`. È esattamente la configurazione coerente con l'architettura: nessuna porta aperta, nessun webhook, nessun certificato da gestire.

1.9 Le credenziali che ti servono

Prima del deploy procurati questi tre valori. Tienili da parte: li scriverai nel `.env` al capitolo 4.

La chiave del provider LLM — una delle due, secondo quale userai.

Anthropic (a pagamento). Su <https://console.anthropic.com>, sezione *API Keys*, crea una chiave. Comincia con `sk-ant-`. Viene mostrata **una volta sola**: copiala subito. Ricorda anche di impostare un limite di spesa mensile nella sezione fatturazione — è la protezione più semplice contro una sorpresa.

Groq (piano gratuito). Su <https://console.groq.com> crea una chiave: comincia con `gsk_`. È l'opzione da scegliere se vuoi tenere la spesa a zero; in cambio i modelli disponibili dipendono dal piano e i limiti di richieste al minuto sono più stretti. Puoi cambiare provider in qualunque momento, è una riga nel `.env`.

Token del bot Telegram. Dal telefono, scrivi a `@BotFather`:


1. `/newbot`
2. scegli un nome visualizzato (per esempio Emma)
3. scegli uno username che finisca per `bot` (per esempio `emma_assistant_bot`)

BotFather risponde con un token nella forma `123456789:AAH...` **È una credenziale:** chi ce l'ha controlla il bot. Non finisce mai in Git, mai in un messaggio, mai in un log.

Il tuo user ID Telegram. Non è lo username con la chiocciola, è un numero. Scrivi a `@userinfobot`: ti risponde con il tuo Id. Quel numero va in `TELEGRAM_ALLOWED_USER_ID` ed è ciò che fa rispondere il bot a te e a nessun altro.


Capitolo 2 — Architettura


2.1 Il quadro d'insieme



Nessuna porta in ingresso. Tutte le frecce verso Internet partono da dentro.

2.2 Il percorso di un messaggio





Se [3] fallisce del tutto, il router non solleva l'errore: risponde "Non riesco a contattare il cervello in questo momento, riprova tra poco", non salva nulla in memoria, e il processo resta vivo.

2.3 Pattern adapter: perché **core/** non sa cosa sia Telegram

È la decisione strutturale più importante del progetto. La regola è una sola: **nessun file sotto **core/** importa Telegram, e nessun concetto di Telegram (chat id, update, formattazione dei messaggi) entra nel core.**

Il confine è materializzato da due oggetti minuscoli in `core/router.py`:

```

AssistantRequest(text: str, user_id: str, conversation_id: str)
AssistantResponse(text: str, degraded: bool = False)

```


L'adapter traduce in entrambe le direzioni: da Update di Telegram a AssistantRequest, e da AssistantResponse a messaggio inviato in chat.

Perché conta: quando arriverà il satellite vocale sul Raspberry, la voce trascritta diventerà un AssistantRequest con lo stesso identico contratto. Il router, la memoria e il client del modello **non cambieranno di una riga**. Se invece il router leggesse `update.message.chat.id`, ogni nuovo canale richiederebbe di rimetterci le mani, e ogni modifica rischierebbe di rompere il canale esistente.

Il costo di questa disciplina è una decina di righe di conversione. Il beneficio è che le fasi 2, 3 e 4 della roadmap si costruiscono sopra invece che dentro.

2.4 Router agencico: il ciclo che oggi gira a vuoto

Un assistente che sa solo rispondere a parole è un chatbot. Uno che può *fare* cose deve poter chiamare degli strumenti, guardare cosa hanno restituito e decidere il passo successivo. Il protocollo dell'API Anthropic per farlo si chiama tool-use, e ha la forma di un ciclo:



Nella v1 la lista dei tool è **vuota**: il modello non può chiedere nulla, quindi il ciclo esce sempre al primo giro. Il codice però c'è tutto, ed è testato. Aggiungere una skill domani significa scrivere una classe con quattro attributi e passarla al router:

```

class Clock:
    name = "current_time"
    description = "Restituisce l'ora corrente."
    input_schema = {"type": "object", "properties": {}}

    async def run(self, arguments: dict) -> str:
        return datetime.now().strftime("%H:%M")
  
```

```
router = Router(llm=llm, memory=memory, system_prompt=prompt, tools=(Clock(),))
```

core/router.py non si tocca. Era questo l'obiettivo.

Due protezioni sono già dentro il ciclo, perché senza di esse sarebbe fragile: un tetto al numero di round (max_tool_iterations, cinque), altrimenti un modello che continua a chiedere strumenti genererebbe una sequenza illimitata di chiamate a pagamento; e il contenimento degli errori dei tool, che vengono restituiti al modello come risultato con is_error invece di propagarsi — una skill difettosa non deve poter far cadere il turno.

2.5 Memoria dietro interfaccia

core/memory.py definisce un'interfaccia astratta con tre operazioni:

```

async def get_history(conversation_id) -> list[StoredMessage]
async def append(conversation_id, message) -> None
async def prune(conversation_id) -> None
  
```

due implementazioni: InMemoryConversationMemory (dizionario in RAM, perduta al riavvio, usata nei test) e SqliteConversationMemory (file SQLite via aiosqlite, persistente tra i riavvii, attiva in produzione dalla v0.2). Entrambe condividono la stessa finestra scorrevole di MAX_HISTORY_MESSAGES messaggi per conversazione.

Il valore dell'interfaccia si è visto con l'introduzione della v0.2: il router non ha cambiato una riga. I test del router girano contro la memoria vera (SQLite su file temporaneo) e verificano il contratto reale indipendentemente dal backend.

Due dettagli non ovvi dell'implementazione attuale:

- **i metodi sono asincroni** anche se oggi non fanno I/O. Un database lo farà, e cambiare la firma da sincrona ad asincrona più avanti significherebbe toccare il router: esattamente ciò che l'interfaccia esiste per evitare.
- **la finestra non comincia mai con un messaggio dell'assistente.** L'API Messages rifiuta una conversazione che non parte dall'utente; se il taglio lasciasse in testa una risposta, viene scartato un messaggio in più. Senza questa regola, con un valore dispari di `MAX_HISTORY_MESSAGES` il sistema si romperebbe a caso dopo qualche scambio.

2.6 Resilienza: tre livelli

L'assistente deve fallire bene. Ci sono tre reti di sicurezza sovrapposte, ciascuna per un tipo diverso di guasto.

Livello 1 — la chiamata al modello (`core/llm.py`). Tre tentativi con attesa esponenziale: subito, dopo 1 secondo, dopo 2. Assorbe i disturbi brevi — un pacchetto perso, un 529 di sovraccarico dell'API — senza che tu te ne accorga. I retry interni del SDK sono disattivati (`max_retries=0`) perché altrimenti i tentativi reali sarebbero nove, con attese moltiplicate. Si ritenta solo ciò che ha senso ritentare: un 401 per chiave sbagliata fallisce al primo colpo, perché riprovare non la farebbe diventare giusta.

Livello 2 — il turno (`core/router.py`). Se tutti i tentativi falliscono, l'eccezione non risale: diventa una risposta di cortesia. Ricevi *“Non riesco a contattare il cervello in questo momento, riprova tra poco”*, il processo resta vivo e il turno fallito non viene salvato in memoria — altrimenti la conversazione si riempirebbe di scuse che il modello poi cercherebbe di spiegare.

Livello 3 — il processo (`systemd/emma.service`). Se il processo muore davvero — un bug non previsto, l'OOM killer, un riavvio della macchina — `Restart=always` lo riporta su dopo 5 secondi. Con un limite: cinque fallimenti in cinque minuti e `systemd` si ferma, perché a quel punto la causa non è transitoria (tipicamente un `.env` sbagliato) e continuare a riavviare nasconderebbe il problema invece di risolverlo.

2.7 Perché FastAPI se non c'è niente da esporre

Domanda legittima: il bot funziona in long polling, non riceve richieste HTTP. Perché un web server?

Due motivi, uno immediato e uno futuro. L'immediato è l'endpoint `/health` su `127.0.0.1:8000`: un `curl` dice se il processo è vivo e quale modello sta usando, senza dover leggere i log. Il futuro è il satellite vocale sul Raspberry, che dovrà parlare con il nodo centrale via HTTP: quando arriverà, il server ci sarà già e l'avvio non andrà ripensato.

FastAPI e il polling di Telegram condividono **un solo event loop**: `uvicorn` possiede il loop, e l'adapter Telegram viene avviato e fermato dal *lifespan* dell'applicazione. Questo significa che un `systemctl stop emma` chiude il polling in modo pulito invece di ucciderlo a metà di un update.

Nel `REVISIONE.md` trovi la discussione critica di questa scelta, insieme all'alternativa senza web server.

2.8 Il provider e il modello

EMMA supporta due backend LLM selezionabili tramite la variabile `LLM_PROVIDER`:

Valore	Backend	Costo
<code>anthropic</code> (default)	Claude via Anthropic API	a pagamento per token
<code>groq</code>	Llama / GPT-OSS via Groq API	tier gratuito disponibile

Anthropic

Il default è **Claude Sonnet 4.6** (`claude-sonnet-4-6`). `ANTHROPIC_MODEL` accetta qualunque identificativo valido — cambia la riga in `.env` e riavvia il servizio, senza modifiche al codice.

Groq (free tier)

Imposta `LLM_PROVIDER=groq` e fornisci una chiave gratuita da console.groq.com. Il modello di default è `openai/gpt-oss-120b`; puoi cambiarlo con `GROQ_MODEL`. I modelli disponibili dipendono dal piano dell'account — per listare quelli accessibili:

```
curl -s -H "Authorization: Bearer $GROQ_API_KEY" \
  https://api.groq.com/openai/v1/models | python3 -c \
  "import json,sys; [print(m['id']) for m in json.load(sys.stdin)['data']]"
```

Capitolo 3 — Implementazione

Questo capitolo spiega il codice file per file: a cosa serve ciascun modulo, come è fatto e perché è fatto così. Serve a te per mantenerlo e a chi vorrà contribuire per orientarsi.

3.1 La mappa

```
emma/
├── main.py                avvio: FastAPI + polling nello stesso event loop
├── config.py              legge e valida .env
├── adapters/
│   └── telegram.py        l'unico file che sa cos'è Telegram
├── core/
│   ├── router.py          orchestratore: contesto → modello → tool → risposta
│   ├── llm.py             client Anthropic/Groq, retry e backoff
│   └── memory.py          interfaccia memoria + implementazioni RAM e SQLite
├── prompts/
│   └── system_prompt.txt   la personalità di EMMA
├── scripts/               backup sul server (bash) e sul PC di sviluppo (PowerShell)
├── systemd/              servizio e timer di backup
├── tests/                 suite pytest, interamente offline
├── data/                  (non in Git) database SQLite delle conversazioni
└── docs/                  questa guida
```

La dipendenza va sempre nella stessa direzione: `main.py` conosce tutti, `adapters/` conosce `core/`, **`core/` non conosce nessuno** se non sé stesso.

3.2 `config.py` — la configurazione

Espone due cose: la dataclass immutabile `Config` e la funzione `load_config()`, unico modo supportato per costruirla.

Il principio è **fallire subito e con chiarezza**. Ogni variabile obbligatoria mancante, ogni numero malformato, ogni file di personalità illeggibile solleva un `ConfigError` che nomina la variabile colpevole. Se il processo supera l'avvio, la configurazione è valida e nessun altro modulo deve più controllarla.

Dettagli che vale la pena conoscere:

- **le variabili d'ambiente reali vincono sul `.env`** (`override=False`). È ciò che permette a `systemd`, o a un test, di sovrascrivere una singola impostazione senza modificare file.
- **i percorsi relativi sono ancorati alla directory del progetto**, non alla working directory: `SYSTEM_PROMPT_PATH=prompts/system_prompt.txt` funziona identico che tu lanci il processo da `/opt/emma` o da `/`.
- **`BACKUP_DIR` e `BACKUP_KEEP` non sono usate dall'applicazione** — le legge `scripts/backup.sh` per conto proprio. Vengono validate qui lo stesso, così un `BACKUP_KEEP=zero` lo scopri all'avvio del servizio e non alle 3:30 di notte.
- **il file di personalità viene letto all'avvio** apposta, per trasformare un percorso sbagliato in un errore di configurazione invece che in una sorpresa al primo messaggio.

3.3 `core/memory.py` — la memoria

`ConversationMemory` è la classe astratta con i tre metodi visti al capitolo 2. `StoredMessage` è la coppia ruolo/testo che ci viaggia dentro.

Il modulo fornisce due implementazioni concrete.

`InMemoryConversationMemory` usa un dizionario di liste in RAM. È usata nei test (veloce, senza I/O) ma perde tutto al riavvio del processo.

`SqliteConversationMemory` (attiva in produzione dalla v0.2) persiste i messaggi in un file SQLite via `aiosqlite`. Va aperta con `open()` all'avvio e chiusa con `close()` allo spegnimento — il lifespan di FastAPI se ne occupa. Il percorso del file si controlla con `MEMORY_DB_PATH` (default `data/emma.db`); la directory viene creata automaticamente se non esiste.

Tre scelte implementative comuni a entrambe:

- **un `asyncio.Lock` protegge le sequenze leggi-modifica-scrivi.** PTB può eseguire due handler in concorrenza, e senza il lock due messaggi ravvicinati potrebbero corrompere la finestra.
- **`get_history` restituisce sempre una copia**, così chi la riceve può manipolarla senza modificare per sbaglio lo stato condiviso.
- **`prune` è idempotente**: chiamarlo due volte di fila non cambia niente. Serve perché venga invocato liberamente, senza doversi chiedere se è già stato fatto.

3.4 `core/llm.py` — il client del modello

È l'unico file che importa gli SDK dei provider (`anthropic` e `groq`). Contiene due classi con la stessa interfaccia — `AnthropicLanguageModel` e `GroqLanguageModel` — scelte in `main.py` in base a `LLM_PROVIDER`. Il router non sa quale delle due sta usando. Entrambe fanno tre cose.

Nasconde il SDK. Le risposte vengono convertite in tipi nostri — `TextBlock` e `ToolUseBlock` dentro un `LLMResponse` — così il router non dipende dagli oggetti del SDK. I blocchi di tipo sconosciuto vengono ignorati invece di sollevare un errore: un'aggiunta futura all'API non deve poter fermare l'assistente in funzione.

Applica la politica di retry. Tre tentativi, attesa 1s e 2s, timeout di 60 secondi per richiesta. Ogni tentativo fallito produce una riga di log con il tipo di errore; il successo ne produce una con `stop_reason` e i token consumati in ingresso e in uscita — è da lì che si capisce quanto costa davvero l'assistente.

Traduce il fallimento definitivo in `LLMUnavailableError`, che è ciò che il router intercetta per rispondere con cortesia. Solo gli errori transitori (problemi di connessione, 5xx) vengono ritentati: un 4xx permanente — chiave sbagliata, richiesta malformata — fallisce subito, senza bruciare tre secondi in tentativi inutili.

Un metodo merita attenzione: `to_assistant_message()`. L'API Messages è *stateless*, quindi per continuare un turno agentico bisogna rimandare la risposta precedente del modello parola per parola, blocchi di tool compresi. Quel metodo la ricostruisce nel formato giusto.

3.5 core/router.py — l’orchestratore

Il cuore. Contiene gli oggetti di confine (AssistantRequest, AssistantResponse), il protocollo Tool e la classe Router.

`handle()` esegue un turno completo e **non solleva mai** eccezioni dovute al modello o a un tool: qualunque guasto diventa una risposta degradata ma educata. I tre messaggi di fallback (modello irraggiungibile, risposta vuota, troppi passaggi) sono costanti in cima al file — sono le uniche stringhe italiane del codice, perché sono le uniche che leggi tu e non un programmatore.

`_run_agentic_loop()` è il ciclo tool-use. `_execute_tool()` esegue un singolo strumento e ne cattura le eccezioni, restituendole al modello come risultato d’errore.

Una regola di comportamento che vale la pena conoscere: **i turni degradati non vengono salvati in memoria**. Se il modello era irraggiungibile, la tua domanda e la risposta di cortesia spariscono, così il messaggio successivo riparte da una cronologia pulita invece che da una scusa.

3.6 adapters/telegram.py — il canale

Costruisce l’Application di `python-telegram-bot`, registra un solo handler per i messaggi di testo e un gestore di errori che logga qualunque eccezione sfugga, tenendo il bot in piedi.

Punti da conoscere:

- **la whitelist è un controllo esplicito nell’handler**, non un filtro di PTB, perché così un tentativo da parte di uno sconosciuto lascia una riga WARNING nei log. Se qualcuno trova il tuo bot, te ne accorgi.
- **drop_pending_updates=True all’avvio**. Dopo un riavvio ricevi un assistente vivo, non una raffica di risposte a domande di tre ore prima.
- **le risposte lunghe vengono spezzate**. Telegram rifiuta i messaggi oltre 4096 caratteri; il taglio preferisce un a capo vicino al limite, per non spezzare righe e paragrafi a metà.
- **l’indicatore “sta scrivendo”** viene inviato prima di chiamare il modello, così i due secondi di attesa non sembrano un silenzio.
- **i comandi (/start e simili) sono ignorati** nella v1. È una semplificazione voluta: l’unica interazione è scrivere in linguaggio naturale.

3.7 main.py — l’avvio

È il *composition root*: l’unico punto in cui si scelgono le classi concrete.

```
llm      = AnthropicLanguageModel(...)           # o GroqLanguageModel, secondo LLM_PROVIDER
memory   = SqliteConversationMemory(...)         # persistente dalla v0.2
router   = Router(llm, memory, prompt, tools=()) # ← qui si registrano le skill
telegram = TelegramAdapter(token, user_id, router)
```

Sostituire un componente è una riga in questo file. È il posto giusto in cui guardare per capire come è montato il sistema.

Il *lifespan* di FastAPI apre il database, avvia il polling all’avvio del server e allo spegnimento fa il percorso inverso: ferma il polling, chiude il pool di connessioni HTTP verso il provider e chiude il database. Il logging è configurato una volta sola su stdout, nel formato `timestamp | LIVELLO | logger | messaggio`, con i logger delle librerie HTTP silenziati: sotto long polling emetterebbero una riga ogni pochi secondi senza dire nulla.

`main()` restituisce 2 se la configurazione non è valida, e logga l'errore senza traceback: un `.env` sbagliato è un errore d'uso, e trenta righe di stack nasconderebbero l'unica che conta.

3.8 tests/ — la suite

Quarantatré test, tutti offline. Il modello è sostituito da `ScriptedModel`, un finto client che restituisce risposte preparate e registra cosa gli è stato chiesto: implementa la stessa interfaccia del client vero, quindi verifica il contratto reale.

Come sono distribuiti:

File	Test	Cosa copre
<code>test_router.py</code>	12	turno semplice, cronologia, isolamento fra conversazioni, ciclo tool completo con formato dei <code>tool_result</code> , tool sconosciuto, tool che esplode, tetto ai round, modello irraggiungibile, risposta vuota, turno fallito
<code>test_memory_sqlite.py</code>	10	che non inquina il successivo come sopra, più la persistenza attraverso chiusura e riapertura del database
<code>test_memory.py</code>	9	finestra scorrevole, regola del primo messaggio utente, idempotenza di prune, copia difensiva
<code>test_llm.py</code>	6	distinzione fra errori transitori (da ritentare) e permanenti (da propagare subito)
<code>test_telegram.py</code>	6	<code>_split_message</code> , incluse le righe vuote a cavallo di un taglio

Non puntano alla copertura totale: puntano ai punti in cui una regressione sarebbe silenziosa.

```
pytest          # nella directory del progetto, con il virtualenv attivo
```

Capitolo 4 — Deploy

Da qui in avanti si lavora sul server, con l'ambiente preparato al capitolo 1.

4.1 Il repository su GitHub

Il progetto nasce come repository Git. Sul PC di sviluppo Windows, dalla cartella del progetto:

```
git init
git add .
git commit -m "initial commit: EMMA v0.1.0, text-only assistant"
git tag -a v0.1.0 -m "v0.1.0 - first working release"
```

Crea poi un repository **privato** su GitHub (lo renderai pubblico tu al momento della release) e collegalo:

```
git remote add origin https://github.com/<tuo-account>/emma.git
git branch -M main
git push -u origin main --tags
```

Verifica. Su GitHub devi vedere i file e **non** devi vedere `.env`. Se lo vedi, fermati: il file è stato committato, la chiave è compromessa e va revocata subito su `console.anthropic.com` prima di qualunque altra cosa.

4.2 Scaricare il codice sul server

```
sudo -u emma git clone https://github.com/<tuo-account>/emma.git /opt/emma
cd /opt/emma
```

Se la directory `/opt/emma` esiste già ed è vuota (l'abbiamo creata al capitolo 1), `git clone` la usa senza problemi. Se protesta perché non è vuota, clona in `/tmp` e sposta il contenuto.

Con repository privato, `git clone` chiede le credenziali: usa un *personal access token* GitHub al posto della password, oppure una chiave SSH di deploy. Il token va salvato con `git config --global credential.helper store` **solo** se accetti che finisca in chiaro in `~/.git-credentials` dell'utente emma.

4.3 L'ambiente virtuale

```
sudo -u emma python3 -m venv /opt/emma/.venv
sudo -u emma /opt/emma/.venv/bin/pip install --upgrade pip
sudo -u emma /opt/emma/.venv/bin/pip install -r /opt/emma/requirements.txt
```

Il `virtualenv` isola le dipendenze di EMMA dal Python di sistema: nessun rischio di rompere strumenti di Ubuntu che usano Python, e nessun bisogno di `--break-system-packages`.

Verifica.

```
sudo -u emma /opt/emma/.venv/bin/pip list | grep -Ei "anthropic|groq|aiosqlite|teleg"
```

Devi vedere tutte le librerie con le versioni esatte scritte in `requirements.txt`.

4.4 Il file .env

```
sudo -u emma cp /opt/emma/.env.example /opt/emma/.env
sudo -u emma chmod 600 /opt/emma/.env
sudo -u emma nano /opt/emma/.env
```

600 significa: solo l'utente emma può leggerlo e scriverlo. Nessun altro utente della macchina, nemmeno il tuo, può vedere la chiave API senza sudo.

Compila i valori obbligatori con le credenziali del paragrafo 1.9.

Con Anthropic (default):

```
LLM_PROVIDER=anthropic
ANTHROPIC_API_KEY=sk-ant-...           # la tua chiave
TELEGRAM_BOT_TOKEN=123456789:AAH...    # il token di BotFather
TELEGRAM_ALLOWED_USER_ID=123456789     # il tuo ID numerico
```

Con Groq (free tier):

```
LLM_PROVIDER=groq
GROQ_API_KEY=gsk_...                   # chiave da console.groq.com
TELEGRAM_BOT_TOKEN=123456789:AAH...
TELEGRAM_ALLOWED_USER_ID=123456789
```

E controlla gli opzionali, che hanno già default sensati:

Variabile	Default	Significato
LLM_PROVIDER	anthropic	backend LLM: anthropic o groq
ANTHROPIC_MODEL	claude-sonnet-4-6	modello Anthropic
GROQ_MODEL	openai/gpt-oss-120b	modello Groq
MAX_HISTORY_MESSAGES	20	messaggi tenuti nella finestra di contesto
MEMORY_DB_PATH	data/emma.db	file SQLite della cronologia; creato al primo avvio
SYSTEM_PROMPT_PATH	prompts/system_prompt.txt	file con la personalità
BACKUP_DIR	/mnt/backup/emma	dove finiscono gli archivi
BACKUP_KEEP	14	quanti archivi conservare

Se al capitolo 1.7 hai montato il disco su un percorso diverso, correggi BACKUP_DIR adesso.

Verifica.

```
ls -l /opt/emma/.env
# -rw----- 1 emma emma ... /opt/emma/.env
git -C /opt/emma status --short
# non deve comparire .env
```

4.5 Primo avvio a mano

Prima di installare il servizio, prova che tutto funzioni in primo piano, dove i messaggi d'errore si leggono subito:

```
cd /opt/emma
sudo -u emma /opt/emma/.venv/bin/python main.py
```

Devi vedere qualcosa come:

```
2026-08-31T14:02:10+0200 | INFO      | emma | starting emma (provider=anthropic, model=
sonnet-4-6, history=20 messages, db=data/emma.db)
2026-08-31T14:02:11+0200 | INFO      | adapters.telegram | telegram adapter started (lo
INFO:      Uvicorn running on http://127.0.0.1:8000
```

Al primo avvio la directory data/ e il file del database vengono creati automaticamente: non devi preparare nulla a mano.

Ora la prova vera: prendi il telefono e scrivi al tuo bot. Entro un paio di secondi devi ricevere una risposta, e sul terminale devono comparire le righe incoming message from chat_id=... e answered chat_id=....

Se non succede nulla, salta al paragrafo 6.7: i tre motivi più comuni sono un token sbagliato, un TELEGRAM_ALLOWED_USER_ID che non è il tuo, e l'aver scritto a un bot diverso da quello del token.

Ferma il processo con Ctrl+C.

4.6 Il servizio systemd

```
sudo cp /opt/emma/systemd/emma.service /etc/systemd/system/
sudo systemctl daemon-reload
sudo systemctl enable --now emma.service
```

enable --now fa due cose insieme: avvia il servizio adesso e lo configura per partire da solo a ogni avvio della macchina.

Se hai installato EMMA in un percorso diverso da /opt/emma, prima di copiare il file modifica le righe marcate # PATH: e la coppia User=/Group=.

Verifica.

```
systemctl status emma.service
```

Devi leggere Active: active (running). Poi:

```
curl -s http://127.0.0.1:8000/health
# {"status":"ok","model":"claude-sonnet-4-6","provider":"anthropic","uptime_seconds":...}

journalctl -u emma -n 30 --no-pager
```

E di nuovo la prova che conta: scrivi al bot dal telefono e verifica di ricevere risposta.

Verifica del riavvio automatico (è un criterio di accettazione, vale la pena provarlo davvero):

```
sudo systemctl kill -s SIGKILL emma.service    # simula un crash brutale
sleep 8
systemctl status emma.service                  # deve essere di nuovo running
```

Nei log vedrai la ripartenza. Se dopo dieci secondi il servizio non è tornato su, qualcosa nella unit non va: controlla `journalctl -u emma -n 50`.

4.7 Il timer di backup

```
sudo cp /opt/emma/systemd/emma-backup.service /etc/systemd/system/
sudo cp /opt/emma/systemd/emma-backup.timer /etc/systemd/system/
sudo systemctl daemon-reload
sudo systemctl enable --now emma-backup.timer
```

Se `BACKUP_DIR` non è sotto `/mnt/backup`, correggi `ReadWritePaths=` e `RequiresMountsFor=` in `emma-backup.service` (righe marcate `# PATH:`) prima di copiarlo: con `ProtectSystem=strict` il filesystem è in sola lettura per il servizio, e senza quella riga il backup fallisce con un permesso negato.

Fai subito una prova a mano, senza aspettare le 3:30:

```
sudo systemctl start emma-backup.service
journalctl -u emma-backup.service -n 30 --no-pager
ls -lh /mnt/backup/emma/
```

Verifica. Deve esserci un file `emma-AAAAMMGG-HHMMSS.tar.gz` con permessi `-rw-----`. Controlla anche il contenuto:

```
tar -tzf /mnt/backup/emma/emma-*.tar.gz | head -20
tar -xzf /mnt/backup/emma/emma-*.tar.gz MANIFEST.txt
```

Devono comparire i file del progetto, il `.env` e il manifesto con data e commit Git di provenienza.

```
systemctl list-timers emma-backup.timer
```

Ti dice quando scatterà la prossima esecuzione.

4.8 Riepilogo: cosa c'è ora sulla macchina

Percorso	Cosa contiene	Permessi
<code>/opt/emma</code>	codice, virtualenv, prompt	750 emma:emma
<code>/opt/emma/.env</code>	chiave API e token	600 emma:emma
<code>/opt/emma/data/emma.db</code>	cronologia delle conversazioni	emma:emma
<code>/mnt/backup/emma</code>	archivi datati	700 emma:emma
<code>/etc/systemd/system/emma.service</code>	il servizio	root
<code>/etc/systemd/system/emma-backup.timer</code>	il backup	root
<code>backup.{service,timer}</code>		

Nessuna porta in ascolto verso l'esterno; una sola regola nel firewall, per SSH.

Capitolo 5 — Utilizzo

5.1 Il giorno per giorno

Apri Telegram, scrivi al bot, ricevi la risposta. È tutto.

EMMA ricorda la conversazione: puoi fare domande di seguito senza ripetere il contesto (“e domani?” dopo aver chiesto del meteo funziona). La memoria copre gli ultimi `MAX_HISTORY_MESSAGES` messaggi — con il default di 20, circa dieci scambi — e **dalla v0.2 sopravvive ai riavvii**: dopo un `systemctl restart` o un riavvio della macchina la conversazione riparte da dove l’avevi lasciata.

Tempi di risposta tipici: uno o due secondi. L’indicatore “sta scrivendo” compare subito, così sai che il messaggio è arrivato.

5.2 Cosa aspettarsi

EMMA nella v1 è una conversazione con un modello linguistico, con una personalità definita in `prompts/system_prompt.txt`: risposte brevi, italiano, tono diretto, nessun preambolo. Va bene per ragionare su un problema, farsi spiegare qualcosa, buttare giù un testo, riordinare le idee.

Non ha accesso a Internet in tempo reale, ai tuoi file, al calendario, alla casa. Se le chiedi il meteo di adesso ti dirà che non può saperlo — e questo è il comportamento voluto: meglio un “non lo so” onesto di un’informazione inventata.

5.3 Personalizzare il carattere

Il file `prompts/system_prompt.txt` è la personalità, in italiano, in chiaro. Modificalo quando vuoi:

```
sudo -u emma nano /opt/emma/prompts/system_prompt.txt
sudo systemctl restart emma.service
```

Il prompt viene letto all’avvio, quindi **il riavvio serve**. Qualche consiglio: descrivi il comportamento, non l’identità (“rispondi in due frasi” funziona meglio di “sii conciso”); dichiara esplicitamente cosa non può fare, così eviti che inventi; e tieni il file corto, perché viene inviato a ogni singolo messaggio e quindi lo paghi ogni volta.

Se modifichi questo file **committalo**: fa parte del progetto e va versionato come il codice.

5.4 Quanto costa

Dipende dal provider. Con `LLM_PROVIDER=groq` sul piano gratuito **non costa nulla**, entro i limiti di richieste al minuto dell’account: è l’opzione da preferire se l’obiettivo è tenere la spesa a zero.

Con Anthropic si paga a token. Ogni messaggio consuma token in ingresso (il prompt di sistema, la finestra di conversazione, la tua domanda) e in uscita (la risposta). Con Sonnet e un uso personale si parla di pochi euro al mese, ma dipende da quanto scrivi.

I numeri veri sono nei log:

```
journalctl -u emma | grep -E "(anthropic|groq) call ok" | tail -20
# ... anthropic call ok (attempt 1): stop_reason=end_turn in=412 out=87
```

in e out sono i token consumati. Il consuntivo ufficiale è nella dashboard di Anthropic; il consiglio pratico è impostare lì un limite di spesa mensile.

Il parametro che sposta di più il costo è `MAX_HISTORY_MESSAGES`: raddoppiarlo raddoppia all'incirca i token in ingresso di ogni messaggio, perché l'intera finestra viene rimandata ogni volta.

5.5 Limiti noti della versione 1

Sono limiti dichiarati, non difetti. Ognuno ha già la sua fase nella roadmap.

- **Nessuno strumento.** Niente meteo, calendario, note, luci, ricerche. → v0.3, skill.
- **Nessuna voce.** Solo testo, solo Telegram. → v0.4, satellite Raspberry.
- **Solo testo in ingresso.** Foto, audio e documenti inviati al bot vengono ignorati senza risposta.
- **I comandi Telegram non fanno nulla.** `/start` e simili sono ignorati: scrivi normalmente.
- **Un solo utente.** Chiunque altro viene ignorato in silenzio, per progetto.
- **Nessuna cancellazione della conversazione dal telefono.** Dalla v0.2 la memoria è persistente, quindi un riavvio non basta più: per ripartire da zero cancella il file del database e riavvia il servizio (paragrafo 5.6).

5.6 Azzerare la memoria

La cronologia sta in un file SQLite, per default `/opt/emma/data/emma.db`. Per ripartire da zero:

```
sudo systemctl stop emma.service
sudo -u emma rm /opt/emma/data/emma.db
sudo systemctl start emma.service
```

Il database viene ricreato vuoto al primo messaggio. Non serve toccare altro.

Se vuoi conservare la cronologia prima di cancellarla, copiala altrove: è un file SQLite normale, leggibile con `sqlite3 emma.db "SELECT * FROM messages;"`. Tienilo dove tieni i backup — contiene le tue conversazioni.

Capitolo 6 — Manutenzione

6.1 Leggere i log

Tutto finisce nel journal di systemd. I comandi che userai davvero:

```
journalctl -u emma -f # in diretta (Ctrl+C per uscire)
journalctl -u emma -n 100 --no-pager # ultime 100 righe
journalctl -u emma --since "1 hour ago" # ultima ora
journalctl -u emma --since today -p err # solo errori di oggi
journalctl -u emma -u emma-backup --since "2 days ago" # servizio e backup insieme
```

Il formato di ogni riga è timestamp | LIVELLO | modulo | messaggio. Cosa significano le righe che vedrai più spesso:

Riga	Significato
starting emma (provider=..., model=..., history=..., db=...)	avvio, con la configurazione in uso
telegram adapter started (long polling)	il bot è connesso e in ascolto
incoming message from chat_id=...	è arrivato un tuo messaggio
anthropic call ok (attempt 1): ... in=N out=M	risposta ottenuta, token consumati (con Groq: groq call ok)
answered chat_id=... (degraded=False)	risposta inviata
ignored message from user_id=... (not in whitelist)	qualcun altro ha scritto al bot
anthropic call failed (attempt 1/3)	tentativo fallito, sta riprovando
giving up on this turn, model unreachable	tutti i tentativi falliti, risposta di cortesia

Quanto spazio occupa il journal e come limitarlo:

```
journalctl --disk-usage
sudo journalctl --vacuum-time=30d # tiene solo gli ultimi 30 giorni
```

6.2 La regola d'oro: prima il backup

Nessun aggiornamento di codice o di dipendenze senza uno snapshot precedente. Non è una raccomandazione, è il primo passo obbligatorio di ogni procedura di questo capitolo. Ci vogliono dieci secondi e ti separa da un pomeriggio di ricostruzione.

```
sudo systemctl start emma-backup.service
journalctl -u emma-backup.service -n 20 --no-pager # controlla che sia andato bene
ls -lht /mnt/backup/emma/ | head -3 # l'archivio più recente è di adesso
```

Se il backup fallisce, **fermati**: risolvi quello prima di toccare qualunque altra cosa.

6.3 Aggiornare il codice: PC di sviluppo → GitHub → server

Il flusso è sempre lo stesso e va in una sola direzione. **Sul server non si modifica mai il codice a mano**: se lo facessi, il `git pull` successivo entrerebbe in conflitto e ti troveresti due versioni divergenti senza sapere quale è quella buona.

Sul PC di sviluppo (Windows)

```
# 1. Snapshot locale, indipendente da Git
powershell -ExecutionPolicy Bypass -File .\scripts\backup-dev.ps1
```

```
# 2. Le modifiche, con le verifiche
ruff format .
ruff check .
pytest
```

```
# 3. Commit e push
git add -A
git commit -m "descrizione di cosa cambia e perché"
git push
```

Se la modifica è una release, aggiorna `CHANGELOG.md`, incrementa la versione secondo semver e aggiungi il tag:

```
git tag -a v0.1.1 -m "v0.1.1 - descrizione breve"
git push --tags
```

Il criterio semver, in breve: **patch** (0.1.x) per correzioni che non cambiano il comportamento; **minor** (0.x.0) per funzionalità nuove compatibili; **major** (x.0.0) per cambiamenti che rompono la compatibilità — nel nostro caso, tipicamente una variabile `.env` rinominata o rimossa.

Sul server

```
# 1. BACKUP OBBLIGATORIO
sudo systemctl start emma-backup.service
journalctl -u emma-backup.service -n 20 --no-pager

# 2. Annota la versione attuale, per poter tornare indietro
cd /opt/emma
git rev-parse --short HEAD          # per esempio alb2c3d - segnatelo

# 3. Scarica le modifiche
sudo -u emma git -C /opt/emma pull

# 4. Aggiorna le dipendenze, se requirements.txt è cambiato
sudo -u emma /opt/emma/.venv/bin/pip install -r /opt/emma/requirements.txt

# 5. Verifica prima di riavviare
sudo -u emma /opt/emma/.venv/bin/python -m pytest
```

```
# 6. Riavvia
sudo systemctl restart emma.service
systemctl status emma.service
curl -s http://127.0.0.1:8000/health
```

Verifica finale: scrivi al bot dal telefono. Un servizio `active` (`running`) non dimostra che l'assistente risponde; un messaggio sì.

Se qualcosa va storto, il paragrafo 6.6 spiega come tornare indietro.

6.4 Aggiornare le dipendenze bloccate

Le versioni in `requirements.txt` sono fissate apposta. Aggiornarle è un'azione deliberata, da fare sul PC di sviluppo, un pacchetto alla volta.

```
# Cosa è invecchiato
pip list --outdated

# Aggiorna una libreria alla volta, non tutte insieme
pip install --upgrade anthropic
pip show anthropic | Select-String Version      # prendi il numero esatto
# scrivi quel numero in requirements.txt

# Verifica
pytest
ruff check .
python main.py          # provalo davvero: scrivi al bot dal telefono

git add requirements.txt
git commit -m "bump anthropic to X.Y.Z"
```

Perché una alla volta: se qualcosa si rompe, sai immediatamente quale libreria è stata. Aggiornandone cinque insieme passeresti un'ora a scoprirlo.

Ogni tanto conviene rigenerare l'ambiente da zero, per accorgersi di una dipendenza che avevi installato a mano e che non è in `requirements.txt`:

```
Remove-Item -Recurse -Force .venv
python -m venv .venv
.\.venv\Scripts\pip install -r requirements.txt
pytest
```

Aggiornamenti di sicurezza del sistema operativo — separati e più semplici:

```
sudo apt update && sudo apt upgrade -y
sudo systemctl status emma.service      # controlla che sia sopravvissuto
```

Se l'upgrade tocca il kernel, pianifica un riavvio: `emma.service` è abilitato, quindi riparte da solo.

6.5 Backup della configurazione e della memoria

Due file **non** sono in Git e vanno protetti dal backup: il `.env`, senza il quale l'assistente non parte, e `data/emma.db`, che contiene tutte le tue conversazioni. Entrambi finiscono in ogni archivio prodotto da `backup.sh` — il `virtualenv` invece è escluso apposta, perché si ricostruisce da `requirements.txt`. È per questi due file che la directory dei backup ha permessi 700.

Se vuoi una copia a parte, per esempio prima di rigenerare la chiave API:

```
sudo cp /opt/emma/.env /mnt/backup/emma/env-$(date +%Y%m%d).bak
sudo chmod 600 /mnt/backup/emma/env-*.bak
```

Non copiarlo in Documenti, non mandartelo via mail, non metterlo in un servizio cloud non cifrato: è una chiave a pagamento e il controllo del tuo bot.

6.6 Ripristino

Un backup mai provato in ripristino non è un backup. Provalo una volta, oggi, quando non serve: scoprire che non funziona mentre serve è tutt'altra esperienza.

6.6.1 Tornare a una versione precedente del codice (senza toccare i backup)

È il caso più frequente: un aggiornamento ha rotto qualcosa e vuoi tornare a prima.

```
cd /opt/emma
git log --oneline -10 # la cronologia: il commit buono è lì
sudo -u emma git checkout a1b2c3d # l'hash annotato al passo 2 del paragrafo 6.3
sudo systemctl restart emma.service
```

Sei ora in *detached HEAD*: va benissimo come misura temporanea. Per tornare all'ultima versione, `sudo -u emma git checkout main`. Se il commit rotto è già su GitHub, la soluzione pulita è correggerlo sul PC di sviluppo con un nuovo commit (o un `git revert`) e rifare il ciclo del paragrafo 6.3 — **non riscrivere la cronologia già pubblicata**, perché romperebbe la copia sul server.

6.6.2 Ripristino completo da un archivio

Serve quando il ripristino da Git non basta: `.env` perso, directory danneggiata, o macchina nuova.

```
# 1. Scegli l'archivio e guarda cosa contiene
ls -lht /mnt/backup/emma/
tar -xZO /mnt/backup/emma/emma-20260829-033012.tar.gz MANIFEST.txt

# 2. Ferma il servizio
sudo systemctl stop emma.service

# 3. Estrai in una directory temporanea (mai direttamente sopra l'installazione)
mkdir -p /tmp/restore
tar -xzf /mnt/backup/emma/emma-20260829-033012.tar.gz -C /tmp/restore
ls /tmp/restore/emma

# 4. Metti da parte l'installazione attuale invece di cancellarla
```

```

sudo mv /opt/emma /opt/emma.rotto-$(date +%Y%m%d)

# 5. Rimetti a posto il ripristino
sudo mv /tmp/restore/emma /opt/emma
sudo chown -R emma:emma /opt/emma
sudo chmod 750 /opt/emma
sudo chmod 600 /opt/emma/.env
# data/emma.db è nell'archivio: le conversazioni tornano com'erano

# 6. Ricrea il virtualenv: nell'archivio non c'è, per scelta
sudo -u emma python3 -m venv /opt/emma/.venv
sudo -u emma /opt/emma/.venv/bin/pip install -r /opt/emma/requirements.txt

# 7. Riparti
sudo systemctl start emma.service
systemctl status emma.service
curl -s http://127.0.0.1:8000/health

```

Verifica: scrivi al bot dal telefono. Solo allora il ripristino è concluso. Quando sei sicuro che tutto funzioni, elimina `/opt/emma.rotto-*`.

6.6.3 Ripristino su una macchina nuova

Stessa procedura, con il capitolo 1 davanti (utente, directory, pacchetti, disco di backup) e i passi 4.6 e 4.7 dietro, per reinstallare le unit systemd. Il contenuto dell'archivio ti restituisce codice, `.env` e personalità: il resto è sistema, e il sistema si ricostruisce da questa guida.

6.6.4 Ripristino dal PC di sviluppo

Gli zip in `D:\EmmaBackups` contengono il progetto **compresa la directory `.git`**, quindi ognuno è un repository completo con tutta la cronologia. Se il repository locale si corrompe:

1. rinomina la cartella di progetto attuale (non cancellarla);
2. estrai lo zip più recente al suo posto;
3. `git status` e `git log --oneline -5` per verificare che la cronologia ci sia;
4. `git push` per riallineare GitHub, se serve.

6.7 Problemi comuni

Il bot non risponde

Nell'ordine:

```

systemctl status emma.service          # 1. il servizio è vivo?
journalctl -u emma -n 50 --no-pager    # 2. cosa dicono i log?
curl -s http://127.0.0.1:8000/health    # 3. il processo risponde?

```

- **Il servizio non è attivo** → guarda l'errore nei log e vai al caso pertinente qui sotto.
- **Il servizio è attivo ma nei log non compare `incoming message`** → il messaggio non arriva affatto. Stai scrivendo al bot giusto? Il `TELEGRAM_BOT_TOKEN` è quello di *quel* bot?

- Nei log c'è **ignored message from user_id=NNN (not in whitelist)** → è il caso più comune in assoluto. Quel numero NNN è il tuo vero user ID: mettilo in `TELEGRAM_ALLOWED_USER_ID` e riavvia. (I log ti hanno appena detto la risposta.)
- C'è **incoming message ma non answered** → il problema è verso Anthropic: cerca `anthropic call failed`.

configuration error: required environment variable ... is missing

Il `.env` manca, è nel posto sbagliato o la variabile è vuota.

```
ls -l /opt/emma/.env
sudo grep -c . /opt/emma/.env      # non deve essere 0
```

Il file deve stare nella directory del progetto, accanto a `main.py`.

configuration error: TELEGRAM_ALLOWED_USER_ID must be an integer

Hai messo lo username invece del numero. Chiedi a @userinfobot il tuo Id e usa quello, senza chiocciola e senza virgolette.

Ricevi sempre “Non riesco a contattare il cervello”

L'API Anthropic non è raggiungibile o rifiuta la chiave. Guarda i log:

```
journalctl -u emma | grep "anthropic call failed" | tail -5
```

- `AuthenticationError / 401` → la chiave è sbagliata, scaduta o revocata. Ne crei una nuova sulla console, la scrivi nel `.env`, `systemctl restart emma`.
- `PermissionDeniedError / 403`, o messaggi su credito → controlla il credito e i limiti di spesa sulla console.
- `APIConnectionError` → problema di rete o DNS del server:

```
curl -sI https://api.anthropic.com | head -1
```

```
resolvectl query api.anthropic.com
```
- `RateLimitError / 429` → stai andando troppo veloce; il retry di solito lo assorbe, se persiste rallenta. Sul piano gratuito di Groq è il caso più comune: i limiti al minuto sono più stretti.

Con `LLM_PROVIDER=groq` valgono gli stessi controlli, cercando `groq call failed` invece di `anthropic call failed`. Un 404 sul nome del modello significa che `GROQ_MODEL` non è disponibile per il tuo account: elenca quelli accessibili con il comando del paragrafo 2.8.

Il servizio riparte in continuazione

```
journalctl -u emma -n 100 --no-pager | grep -i error
```

Quasi sempre è un errore di configurazione che si ripete a ogni avvio. Dopo cinque tentativi in cinque minuti `systemd` si ferma da solo: risolto il problema, `sudo systemctl reset-failed emma.service && sudo systemctl start emma.service`.

Il backup non parte o fallisce

```
journalctl -u emma-backup.service -n 30 --no-pager
systemctl list-timers emma-backup.timer
findmnt /mnt/backup # il disco è montato?
sudo -u emma df -h /mnt/backup # c'è spazio?
```

- **cannot create ... (is the disk mounted?)** → il disco non è montato: `sudo mount -a` e controlla `/etc/fstab` (paragrafo 1.7.3).
- **Permission denied** → o la directory non appartiene a emma, o manca `ReadWritePaths=` nella unit (paragrafo 4.7).
- **Il timer non compare in list-timers** → non è abilitato: `sudo systemctl enable --now emma-backup.timer`.

EMMA non ricorda più niente, oppure il servizio non parte per il database

Dalla v0.2 la cronologia sta in `data/emma.db`. Controlla che il file esista e che l'utente emma possa scriverci:

```
ls -l /opt/emma/data/
sudo -u emma sqlite3 /opt/emma/data/emma.db "SELECT COUNT(*) FROM messages;"
```

- **La directory data/ non esiste** → viene creata al primo avvio; se manca, i permessi di `/opt/emma` non consentono la scrittura: `sudo chown -R emma:emma /opt/emma`.
- **unable to open database file** nei log → stesso problema di permessi, oppure `MEMO-RY_DB_PATH` nel `.env` punta a un percorso non scrivibile.
- **database is locked** → due processi EMMA stanno girando insieme. Controlla con `systemctl status emma.service` e chiudi quello avviato a mano.
- **Il file c'è ma la cronologia è vuota** → normale dopo una cancellazione o al primo avvio; si ripopola dal messaggio successivo.

Le risposte sono strane o fuori carattere

Hai modificato `prompts/system_prompt.txt` e non hai riavviato: il prompt viene letto solo all'avvio. `sudo systemctl restart emma.service`.

git pull dice che ci sono conflitti

Qualcuno — probabilmente tu — ha modificato file direttamente sul server. Per vedere cosa:

```
git -C /opt/emma status
git -C /opt/emma diff
```

Se le modifiche locali non ti servono, `sudo -u emma git -C /opt/emma checkout -- .` le scarta e poi il pull passa. Se ti servono, portale sul PC di sviluppo e falle rientrare dal flusso normale. E ricorda la regola: sul server non si modifica il codice.

6.8 Calendario di manutenzione

Quando	Cosa
Automatico, ogni notte	il backup gira alle 3:30

Quando	Cosa
Ogni settimana	un'occhiata a <code>journalctl -u emma -p err --since "7 days ago"</code>
Ogni mese	<code>sudo apt update && sudo apt upgrade</code> ; controllo della spesa sulla console Anthropic; <code>ls -lh /mnt/backup/emma/</code> per verificare che gli archivi ci siano davvero
Ogni tre mesi	<code>pip list --outdated</code> sul PC di sviluppo e aggiornamento ragionato; prova di ripristino (paragrafo 6.6)
Una volta sola, adesso	la prima prova di ripristino, prima che serva

Appendice A — Comandi di riferimento

Servizio

```
sudo systemctl status emma.service
sudo systemctl restart emma.service
sudo systemctl stop emma.service
sudo systemctl start emma.service
```

Log

```
journalctl -u emma -f
journalctl -u emma -n 100 --no-pager
journalctl -u emma --since today -p err
```

Salute

```
curl -s http://127.0.0.1:8000/health
```

Backup

```
sudo systemctl start emma-backup.service
systemctl list-timers emma-backup.timer
ls -lht /mnt/backup/emma/ | head
```

Memoria: azzerare la cronologia

```
sudo systemctl stop emma.service
sudo -u emma rm /opt/emma/data/emma.db
sudo systemctl start emma.service
```

Aggiornamento (dopo il backup)

```
sudo -u emma git -C /opt/emma pull
sudo -u emma /opt/emma/.venv/bin/pip install -r /opt/emma/requirements.txt
sudo -u emma /opt/emma/.venv/bin/python -m pytest
sudo systemctl restart emma.service
```

Cronologia e ritorno indietro

```
git -C /opt/emma log --oneline -10
sudo -u emma git -C /opt/emma checkout <hash>
sudo -u emma git -C /opt/emma checkout main
```

Appendice B — Le variabili di `.env`

Variabile	Obbligatoria	Default	Note
LLM_PROVIDER	no	anthropic	anthropic o groq
ANTHROPIC_API_KEY	se provider=anthropic	—	comincia con sk-ant-; è un segreto
ANTHROPIC_MODEL	no	claude-sonnet-4-6	qualsunque identificativo valido
GROQ_API_KEY	se provider=groq	—	comincia con gsk-; è un segreto
GROQ_MODEL	no	openai/gpt-oss-120b	dipende dal piano account Groq
TELEGRAM_BOT_TOKEN	sì	—	da @BotFather; è un segreto
TELEGRAM_ALLOWED_USER_ID	sì	—	numero, non username; da @userinfobot
MAX_HISTORY_MESSAGES	no	20	messaggi nella finestra; incide sul costo
MEMORY_DB_PATH	no	data/emma.db	file SQLite della storia; creato automaticamente
SYSTEM_PROMPT_PATH	no	prompts/system_prompt.txt	relativo alla directory del progetto
BACKUP_DIR	no	/mnt/backup/emma	letto da backup.sh
BACKUP_KEEP	no	14	archivi conservati dalla rotazione

Nota: il file SQLite (data/emma.db) contiene la cronologia delle conversazioni e non deve mai essere incluso in un commit Git — `.gitignore` lo esclude già. Per azzerare la memoria basta cancellare il file e riavviare il servizio.

Appendice C — Dove guardare quando qualcosa non torna

Domanda	Risposta
Il servizio è vivo?	<code>systemctl status emma.service</code>
Cosa è successo?	<code>journalctl -u emma -n 100 --no-pager</code>
Il processo risponde?	<code>curl -s http://127.0.0.1:8000/health</code>

Domanda	Risposta
Quale versione è in esecuzione?	<code>git -C /opt/emma log --oneline -1</code>
Quando è stato l'ultimo backup?	<code>ls -lht /mnt/backup/emma/ \ head -3</code>
Quanto sto spendendo?	<code>journalctl -u emma \ grep -E "(anthropic\ groq) call ok" \ tail -20</code>
Quali sono le impostazioni attive?	il log di avvio: <code>journalctl -u emma \ grep "starting emma"</code>
Quante conversazioni sono in memoria?	<code>sudo -u emma sqlite3 /opt/emma/data/emma.db "SELECT conv_id, COUNT(*) FROM messages GROUP BY conv_id;"</code>
Perché è stato deciso così?	REVISIONE.md, e il capitolo 2 di questa guida

EMMA v0.2.0 — guida aggiornata al 31 agosto 2026. Il sorgente di questo documento è docs/GUIDA.md: modificalo lì e rigenera il PDF, così le due versioni non divergono.